تمرین اول درس Big Data

عرفان اشتری 401123916

1)

الف)

در ابتدا کتابخانه های مورد نیاز را فرا میخوانیم و یک فضای pyspark ایجاد میکنیم.

```
from pyspark.sql import SparkSession #Import the pyspark
from pyspark.conf import SparkConf #Import the SparkConf
from pyspark.context import SparkContext #Import the SparkContext
import time

#initializing and starting a pyspark session

conf = SparkConf()
conf.setMaster("local").setAppName("word-counts")
sc = SparkContext.getOrCreate(conf=conf)
```

در ادامه در شروع کار باید ابتدا فایل متنی مورد نظر را توسط اسپارک بخوانیم و سپس تعداد کل کلمات را بخوانیم، جداسازی کلمات را با space (فاصله = " ") در نظر میگیریم و با استفاده از کد زیر یک لیست به دست می آید که هر عضو آن یک تاپل میباشد که شامل کلمه و تعداد تکرار آن است که با جمع کردن همه اعداد به تعداد کل کلمات میرسیم.

```
#reading all the words in the text file and making a list of tupples
including words and their counts
lines = sc.textFile("JaneAusten.txt") #The file is read using the te
xtFile() method.
word_counts = lines.flatMap(lambda line: line.split(' '))\
                   .map(lambda word: (word,1)) \
                   .reduceByKey(lambda count1, count2: count1 + coun
t2) \
                   .collect()


c = 0

#counting all the words
for (word,count) in word_counts[0:]:
#     print(word,count)
    c += count

print("count = ",c)

c = 0

#counting words except for space(" ")
```

```
for (word,count) in word_counts[1:]:
#     print(word,count)
    c += count

print("count words except for space = ",c)
```

در این کد یکبار تعداد کل کلمات بدست آمده و یکبار هم تعداد بدون در نظر گرفتن space و مقادیر آن ها به ترتیب 797474 و 780223 میباشد.

لیست word_counts به شکل زیر می باشد.

```
[('', 17251),
 ('Project', 81),
 ("Gutenberg's", 1),
 ('The', 1663),
 ('Complete', 3),
 ('Works', 3),
 ('of', 22761),
 ('Jane', 374),
 ('Austen,', 6),
 .

 .

 .
 ('utility', 6),
 ('abroad,', 11),
 ('talents', 16),
 ('accomplishments', 9),
 ...]
```

ب)

در این بخش میخواهیم تعداد کلمات بدون تکرار را بدست آوریم برای این کار پس از خواندن فایل متنی مطابق بخش قبل، از کد و توابع زیر استفاده میکنیم.

```
distinct_words_counts = words_counts.distinct() #The unique words
can be found by invoking the distinct() function on the rdd.


count = distinct_words_counts.count() #The count of unique words is
obtained by invoking the count() function.
```

با استفاده از این کدها مقدار count که همان تعداد لغات بدون تکرار است برابر با 44360 بدست آمد.

ج)

در این بخش ابتدا از لیست word_counts استفاده میکنیم و آن را برحسب تعداد تکرار کلمات مرتب میکنیم.

```
#sorting files based on their counts and showing top 10
sort = sorted(word_counts,key=lambda l:l[1], reverse=True)
sort[:10]
```

در نهایت 10 کلمه ای که بیشترین تکرار دارند کلمات زیر میباشند.

```
[('the', 26654),
 ('to', 25322),
 ('of', 22761),
 ('and', 22184),
 ('', 17251),
 ('a', 13772),
 ('I', 11686),
 ('in', 11523),
 ('her', 11427),
 ('was', 11342)]
```

در ادامه برای قسمت بعدی سوال باید شمارش تعداد کلمات بدون تکرار را با استفاده از تعداد 1 تا 4 هسته از پردازشگر انجام دهیم که برای تغییر تعداد هسته ها میبایست در تنظیمات مربوط به راه اندازی اسپارک `conf.setMaster(f"local[{i}]").setAppName("word-counts")` قرار دهیم که در آن `i` نشان دهنده تعداد هسته هاست. کد این بخش به صورت زیر میباشد.

```
#changing the number of processors for exprimenting the process time
T = []
num_cores= [ 1,2,3,4]
for i in num_cores:
    conf = SparkConf()
    conf.setMaster(f"local[{i}]").setAppName("word-counts")   # set
the number of cores
    sc = SparkContext.getOrCreate(conf=conf) #The spark context
object is assigned to a variable sc.
    print(conf.getAll())

    t = time.time()

    lines = sc.textFile("JaneAusten.txt") #The file is read using
the textFile() method.

    words_rdd = lines.flatMap(lambda line: line.split(' '))

    distinct_words_counts = words_rdd.distinct() #The unique words
can be found by invoking the distinct() function on the rdd.
```

```
    count = distinct_words_counts.count() #The count of unique words
is obtained by invoking the count() function.

    print("core:",i)

    print(time.time() - t)
    T.append(time.time() - t)

    print("The count of unique words in the file is:", count)
```

در این بخش لیست num_cores شامل تعداد هسته استفاده شده و لیست T شامل زمان انجام عملیات برای هر تعداد هسته است. برای به دست آوردن زمان از time.time() در ابتدا و انتهای عملیات مورد نظر استفاده شده است. در پایان خروجی زیر برای این بخش بدست آمد

```
[('spark.app.name', 'word-counts'), ('spark.submit.pyFiles', ''),
('spark.submit.deployMode', 'client'), ('spark.app.submitTime',
'1672598316727'), ('spark.ui.showConsoleProgress', 'true'),
('spark.master', 'local[1]')]
core: 1
2.042257070541382
The count of unique words in the file is: 44360


[('spark.app.name', 'word-counts'), ('spark.submit.pyFiles', ''),
('spark.submit.deployMode', 'client'), ('spark.app.submitTime',
'1672598316727'), ('spark.ui.showConsoleProgress', 'true'),
('spark.master', 'local[2]')]
core: 2
1.5026111602783203
The count of unique words in the file is: 44360


[('spark.master', 'local[3]'), ('spark.app.name', 'word-counts'),
('spark.submit.pyFiles', ''), ('spark.submit.deployMode', 'client'),
('spark.app.submitTime', '1672598316727'),
('spark.ui.showConsoleProgress', 'true')]
core: 3
1.3745746612548828
The count of unique words in the file is: 44360


[('spark.master', 'local[4]'), ('spark.app.name', 'word-counts'),
('spark.submit.pyFiles', ''), ('spark.submit.deployMode', 'client'),
('spark.app.submitTime', '1672598316727'),
```

```
('spark.ui.showConsoleProgress', 'true')]

[Stage 590:>
(0 + 1) / 1]
core: 4
1.3995206356048584
The count of unique words in the file is: 44360
```

و با استفاده از کد زیر نمودار مربوط به آن رسم گردید.

```
import matplotlib.pyplot as plt

plt.plot(num_cores,T, color='magenta', marker='o',mfc='pink' ) #plot
the data

plt.ylabel('time') #set the label for y axis
plt.xlabel('number of cores') #set the label for x-axis
plt.title("Time vs number of cores") #set the title of the graph
plt.show() #display the graph
plt.savefig("Time vs number of cores.png")
```

که نتیجه آن به صورت زیر است.

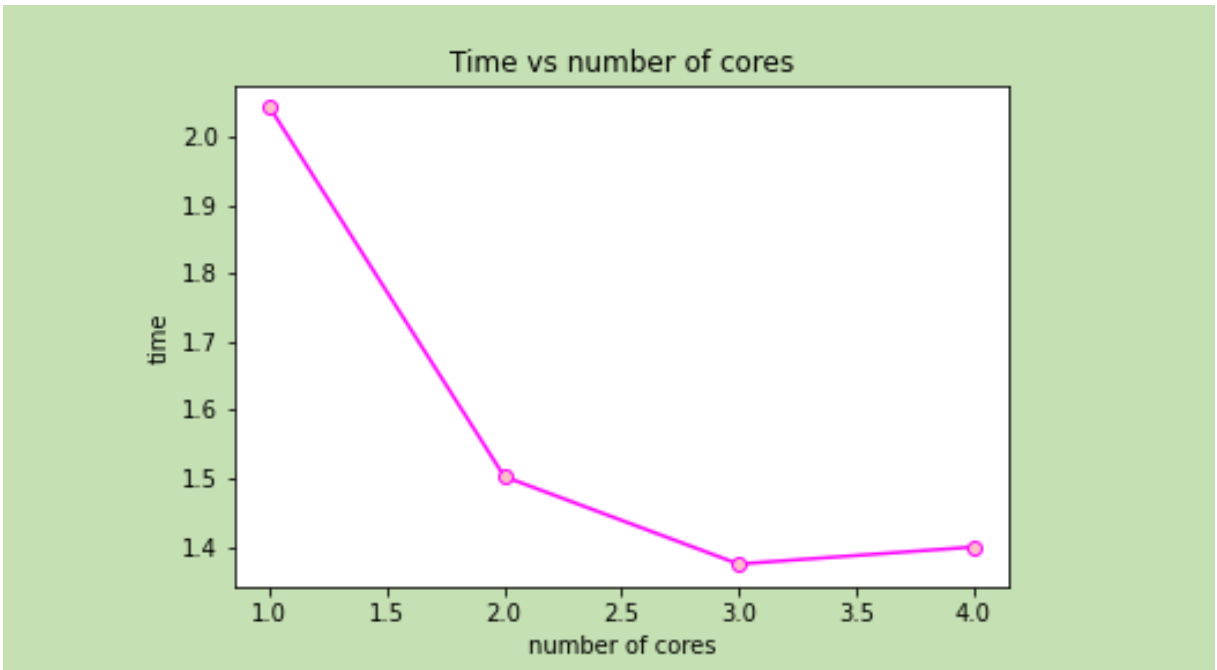

همانطور که قابل مشاهده است با افزایش تعداد هسته از یک به چهار زمان پردازش که برحسب ثانیه است کاهش یافته و تقریبا ثابت شده است و در واقع سرعت پردازش با تعداد هسته های بیشتر افزایش می یابد.

2)

الف)

در این سوال همانند سوال قبل سه فایل متنی مورد نظر را میخوانیم، برای این کار ابتدا کتابخانه های موردنیاز فراخوانده شده و پس از راه اندازی pyspark به سراغ خواندن فایل ها می رویم. کد مورد نیاز برای خواندن فایل متنی اول برای مثال در زیر آمده است.

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from mpl_toolkits.mplot3d import Axes3D
from pyspark import SparkContext
from pyspark.ml.clustering import KMeans, BisectingKMeans
from pyspark.ml.feature import VectorAssembler
from pyspark.sql import SQLContext
from pyspark.sql import SparkSession #Import the pyspark
from pyspark.conf import SparkConf #Import the SparkConf
from pyspark.context import SparkContext #Import the SparkContext
import time

#initializing and starting a pyspark session
conf = SparkConf()
conf.setMaster("local").setAppName("word-counts")

sc = SparkContext.getOrCreate(conf=conf)

df1 = sc.textFile("C1.txt") #The file is read using the textFile() m
ethod.
```

پس از خواندن فایل متنی و ذخیره آن در دیتافریم اسپارک df1 باید ابتدا اطلاعات عددی موجود در آن ها که درواقع همان مختصات میباشند استخراج شود و در نهایت در یک دیتافریم و فایل csv ذخیره شود تا در ادامه راحت تر بتوان از آن استفاده کرد.

```
#  save the numbers in columns of dataframe as lists
L1 = []
L2 = []
for i in range(df1.count()):
    m= df1.collect()[i].find("\t")

    L1.append(df1.collect()[i][:m])
    L2.append(df1.collect()[i][m+1:])

# making a pandas dataframe using the lists
C1_list = pd.DataFrame(
    {'X': L1,
     'Y': L2
```

```
    })

# save the dataframe as a csv file
C1_list.to_csv('C1_pd.csv', index=False)
```

سپس دومرتبه دیتا را با استفاده از کد زیر میخوانیم.

```
sqlContext = SQLContext(sc)



FEATURES_COL = ['X', 'Y']
path = 'C1_pd.csv'

# reading csv file as pyspark dataframe
df = sqlContext.read.csv(path, header=True)
df.show()
```

که نتیجه به صورت زیر است

```
+------+------+
|     X|     Y|
+------+------+
|624474|837604|
|673412|735362|
|647442|677000|
|532283|741384|
|646529|742844|
|647535|755101|
|644131|777721|
|521368|736923|
|688940|798967|
|592666|805244|
|645068|716248|
|666740|707391|
|662064|644958|
|630628|689662|
|623268|774834|
|617896|766560|
|560260|629298|
|595728|703618|
|594177|665266|
|544862|802997|
+------+------+
only showing top 20 rows
```

در ادامه چون ما نیاز داریم جنس دیتا عددی باشد و نه رشته، مقدارهای دیتافریم را به نوع float تغییر میدهیم.

```
df_feat = df.select(*(df[c].cast("float").alias(c) for c in
df.columns[:]))
```

در نهایت هر دو ستون را به یک ستون واحد به نام features تبدیل میکنیم که هر سطر آن شامل یک لیست میباشد که دو مختصات را در خود دارد. کد این بخش به صورت زیر است.

```
#adding a features column which contains all the columns as a single
list

vecAssembler = VectorAssembler(inputCols=FEATURES_COL, outputCol="fe
atures")
# choosing just the features column for a new dataframe
df_kmeans = vecAssembler.transform(df_feat).select('features')
df_kmeans.show()
```

حال در df_kmeans دیتا فریمی داریم که فقط یک ستون features دارد که همه اطلاعات مورد نیاز را دارد.

```
+------------------+
|          features|
+------------------+
|[624474.0,837604.0]|
|[673412.0,735362.0]|
|[647442.0,677000.0]|
|[532283.0,741384.0]|
|[646529.0,742844.0]|
|[647535.0,755101.0]|
|[644131.0,777721.0]|
|[521368.0,736923.0]|
|[688940.0,798967.0]|
|[592666.0,805244.0]|
|[645068.0,716248.0]|
|[666740.0,707391.0]|
|[662064.0,644958.0]|
|[630628.0,689662.0]|
|[623268.0,774834.0]|
|[617896.0,766560.0]|
|[560260.0,629298.0]|
|[595728.0,703618.0]|
|[594177.0,665266.0]|
|[544862.0,802997.0]|
+------------------+
only showing top 20 rows
```

همین کارها را برای دو فایل متنی دیگر نیز انجام می دهیم که اطلاعتشان در نوت بوک موجود است. حالا که دیتا فریم آماده شده است به بخش بعدی میرسیم که اعمال روش های خوشه بندی میباشد، در ابتدا روش خوشه بندی kmeans++ را اعمال میکنیم که برای این کار باید از تابع خوشه بندی kmeans اسپارک استفاده کنیم و مقدار پارامتر initMode را برابر با 'k-means||' قرار دهیم و برای تنظیم تعداد کلاستر از set(k). استفاده شده که k نشان دهنده تعداد کلاستر

است که از 2 تا 25 متغیر است. پس از پایان عملیات برای هر کلاستر مقدار هزینه آن از روش Silhouette score را در لیست cost ذخیره میکنیم که در ادامه برای رسم نمودار استفاده خواهد شد. کد این بخش برای kmeans++ به صورت زیر است.

```
# training a kmeans ++ (initMode='k-means||') model on the dataframe
extracted from the text file
# evaluating using Silhouette methode
from pyspark.ml.evaluation import ClusteringEvaluator
cost = np.zeros(25)
for k in range(2,25):
    kmeans = KMeans(initMode='k-
means||').setK(k).setSeed(1).setFeaturesCol("features")
    model = kmeans.fit(df_kmeans)

    pdt = model.transform(df_kmeans)
    evaluator = ClusteringEvaluator()
    cost[k] = evaluator.evaluate(pdt) #Silhouette with squared
euclidean distance
```

و برای خوشه بندی با Bisecting K-means هم از کد زیر استفاده میکنیم.

```
# training a BisectingKMeans model on the dataframe extracted from
the text file
# evaluating using Silhouette methode
from pyspark.ml.evaluation import ClusteringEvaluator
cost = np.zeros(25)
for k in range(2,25):
    bkm =
BisectingKMeans().setK(k).setSeed(1).setFeaturesCol("features")
    model = bkm.fit(df_kmeans)

    pdt = model.transform(df_kmeans)
    evaluator = ClusteringEvaluator()
    cost[k] = evaluator.evaluate(pdt) #Silhouette with squared
euclidean distance
```

با اعمال این کدها روی دیتافریم های بدست آمده از فایل های متنی به مقدار هزینه یا همان Silhouette score برای هر تعداد کلاستر بین 2 تا 25 در هر فایل میرسیم و با استفاده از کدی مشابه زیر میتوان آن ها را رسم کرد.

```
# ploting Silhouette score vs number of clusters(k)
# the maximum shows the optimal k for the kmeans model
fig, ax = plt.subplots(1,1, figsize =(8,6))
ax.plot(range(2,25),cost[2:25],"bo-")
ax.set_xlabel('k')
ax.set_ylabel('Silhouette score')
```

```
ax.set_title("Silhouette score curve")
plt.savefig("Silhouette score curve.png")
```

البته میتوان مقدار هزینه را از روش Elbow با جایگزینی خط کد زیر با مشابهش در کدهای بالا بدست آورد.

```
cost[k] = model.summary.trainingCost
```

پس از رسم نمودار مربوط به این شیوه ارزیابی مشاهده می شود که این روش نمودارهای نزولی ای مشابه تصویر زیر بدست می دهد که نقاطی که منحنی درآنها زاویه دار شده و یا نقطه ای که تقریبا اندازه خطا ثابت شده را میتوان به عنوان k بهینه در نظرگرفت که برای مثال در این نمودار حوالی 16 و 17 است.

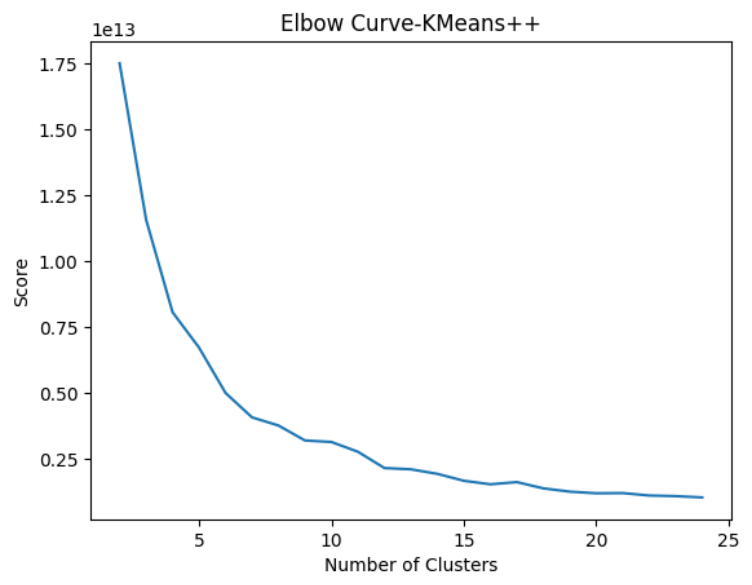

اما از آنجا که محاسبه k بهینه در روش Silhouette ساده تر است و فقط نیاز به ماکزیمم گیری دارد از این روش برای کل حالت ها استفاده شده و در نهایت با رسم نمودار ها به ترتیب برای فایل های متنی به نتایج زیر دست میابیم.

C1: نمودار روش kmeans++ برای فایل اول:

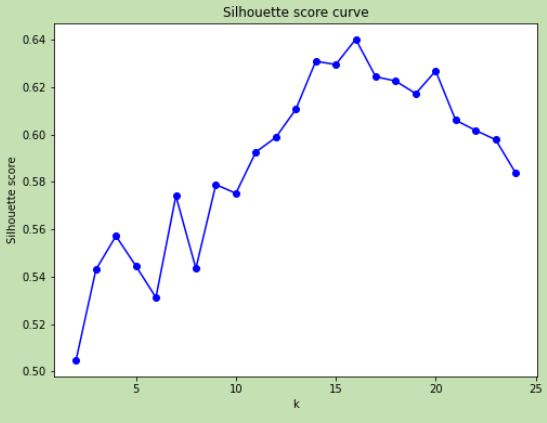

C1: روش Bisecting K-means برای فایل اول:

C2: نمودار روش kmeans++ برای فایل دوم:

C2: روش Bisecting K-means برای فایل دوم:

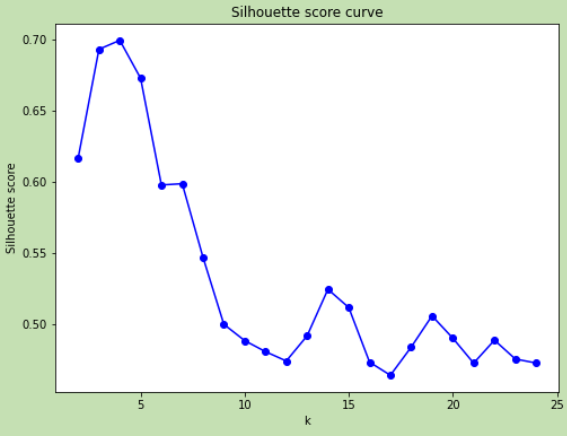

C3: نمودار روش kmeans++ برای فایل سوم:

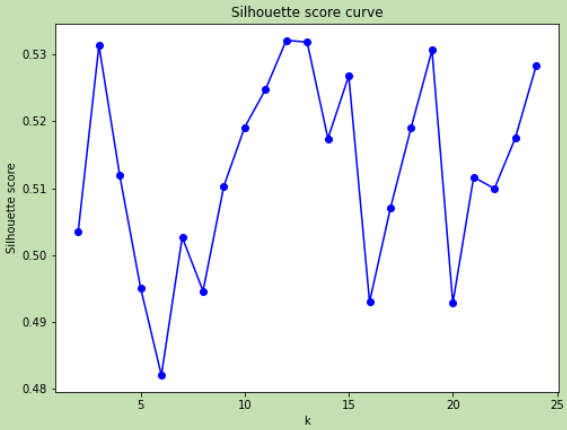

C3: روش Bisecting K-means برای فایل سوم:

ب)

در این بخش میبایست تعداد بهینه خوشه ها را بدست آوریم این کار با استفاده از نمودار های قسمت قبل به راحتی قابل انجام است زیرا در روش Silhouette بهترین تعداد خوشه همان است که مقدار امتیاز Silhouette آن بیشینه شده است و در واقع همان نقطه ماکزیمم نمودار میباشد پس برای این منظور از کد زیر برای همه حالتهای مختلف استفاده میکنیم

```
k = cost.argmax()
print("best k for clustering: ", k)
```

مقدار بهینه k برای هر بخش به این صورت است

برای فایل اول روش kmeans++ مقدار k=16

برای فایل اول روش Bisecting K-means مقدار k=4

برای فایل دوم روش kmeans++ مقدار k=3

برای فایل دوم روش Bisecting K-means مقدار k=4

برای فایل سوم روش kmeans++ مقدار k=12

برای فایل سوم روش Bisecting K-means مقدار k=4

ج)

برای هر فایل روش خوشه بندی ای بهتر است که تعداد بهینه خوشه آن مقدار امتیاز Silhouette بیشتری دارد، با توجه به این نکته و نمودارهای بخش های قبل برای تمام فایل ها در این بخش از روش kmeans++ استفاده میکنیم. البته محاسبات مربوط به این بخش برای همه فایل ها و روش Bisecting K-means در نوت بوک موجود میباشد.

برای بدست آوردن مراکز کلاسترهای برای هر فایل از کد زیر استفاده میکنیم.

```
kmeans = KMeans(initMode='k-means||').setK(k).setSeed(1).setFeatures
Col("features")
model = kmeans.fit(df_kmeans)
centers = model.clusterCenters()

print("Cluster Centers: ")
for center in centers:
    print(center)
```

که در این کد بار دیگر مدل را با تعداد خوشه k اجرا کرده و مراکز را در لیست centers ذخیره میکنیم و نمایش میدهیم که در نهایت برای هریک از فایل ها نتیجه زیر را داریم.

برای فایل اول با 16 کلاستر داریم:

```
Cluster Centers:
[738928.3238342  430720.18393782]
[508472.61237785 219457.78501629]
[289311.39145907 703451.08540925]
[458746.55401662 642691.57617729]
[245168.32397959 493590.78571429]
[383938.31740614 363885.19453925]
[389803.93859649 511164.44736842]
[498527.15755627 778321.        ]
[199636.85714286 314493.9047619 ]
```

```
[541997.53313253 386822.64759036]
[661783.55952381 263828.71130952]
[650725.57931034 756255.30344828]
[768162.48504983 576619.66445183]
[623400.07713499 621188.47658402]
[297558.31476323 276901.95821727]
[546289.03289474 517146.85197368]
```

برای فایل دوم و 3 کلاستر داریم:

```
Cluster Centers:
[15.42522253  7.20756677]
[32.36707314 16.54471542]
[11.01487806 22.77268288]
```

و برای فایل سوم و 12 کلاستر داریم:

```
Cluster Centers:
[24.01666677 27.32222225]
[13.20200012 17.59400002]
[27.4673913  7.7086957]
[14.94318177 25.54772732]
[15.67624998 11.82875001]
[23.07249999 14.42874994]
[ 5.31666666 14.404762  ]
[29.23620684 18.80862065]
[20.17777782 20.94629627]
[ 8.21304347 22.03913042]
[10.28333322  7.6541667 ]
[19.03478253  5.22173915]
```

د)

در این بخش پایانی میخواهیم مدت زمان اجرای عملیات خوشه بندی با هر دو روش و با استفاده از تعداد بهینه خوشه و برای هر 3 فایل را با در نظر گرفتن تعداد 1 تا 4 هسته پردازشگر بدست آورده و مقایسه کنیم، برای این کار از کد زیر برای حالات مختلف استفاده میکنیم.

```
#changing the number of processors for exprimenting the process time of kmeans++ training

T=[]

print("best k for clustering: ", k)

num_cores= [ 1,2,3,4]
```

```
for i in num_cores:

    conf = SparkConf()
    conf.setMaster(f"local[{i}]").setAppName("word-counts")   # set
the number of cores
    sc = SparkContext.getOrCreate(conf=conf) #The spark context obje
ct is assigned to a variable sc.
    print(conf.getAll())

    t = time.time()
    kmeans = KMeans(initMode='k-means||').setK(k).setFeaturesCol("fe
atures")
    model = kmeans.fit(df_kmeans)
    print(time.time() - t)
    T.append(time.time() - t)
```

در این کد مشابه کدی که در سوال اول زده بودیم عمل میکنیم و به همان طریق تعداد هسته های پردازشگر را تغییر میدهیم. و پس از اعمال روش خوشه بندی زمان اجرای عملیات را در لیست T ذخیره میکنیم. همچنین تعداد هسته ها نیز در لیست num_cores ذخیره شده است. خروجی کد بالا برای یک نمونه به این صورت است

```
best k for clustering:  16


[('spark.app.submitTime', '1672647824991'), ('spark.app.name', 'word
-counts'), ('spark.submit.pyFiles', ''), ('spark.submit.deployMode',
'client'), ('spark.ui.showConsoleProgress', 'true'), ('spark.master'
, 'local[1]')]
1.5731873512268066


[('spark.app.submitTime', '1672647824991'), ('spark.app.name', 'word
-counts'), ('spark.submit.pyFiles', ''), ('spark.submit.deployMode',
'client'), ('spark.ui.showConsoleProgress', 'true'), ('spark.master'
, 'local[2]')]
1.3014400005340576


[('spark.app.submitTime', '1672647824991'), ('spark.master', 'local[
3]'), ('spark.app.name', 'word-counts'), ('spark.submit.pyFiles', ''
), ('spark.submit.deployMode', 'client'), ('spark.ui.showConsoleProg
ress', 'true')]
1.1812496185302734


[('spark.app.submitTime', '1672647824991'), ('spark.master', 'local[
4]'), ('spark.app.name', 'word-counts'), ('spark.submit.pyFiles', ''
), ('spark.submit.deployMode', 'client'), ('spark.ui.showConsoleProg
ress', 'true')]
1.2570278644561768
```

پس از بدست آوردن لیست زمان ها برای هر حالت میتوان با استفاده از کد زیر نمودار مربوط به آن را رسم کرد.

```
import matplotlib.pyplot as plt

plt.plot(num_cores,T, color='magenta', marker='o',mfc='pink' ) #plot
the data

plt.ylabel('time') #set the label for y axis
plt.xlabel('number of cores') #set the label for x-axis
plt.title("Time vs number of cores (C1)") #set the title of the
graph
plt.show() #display the graph
plt.savefig("Time vs number of cores_C1.png")
```

پس از رسم نمودارها نتایج به صورت زیر بدست می آیند.

C1: نمودار روش kmeans++ برای فایل اول با k= 16:

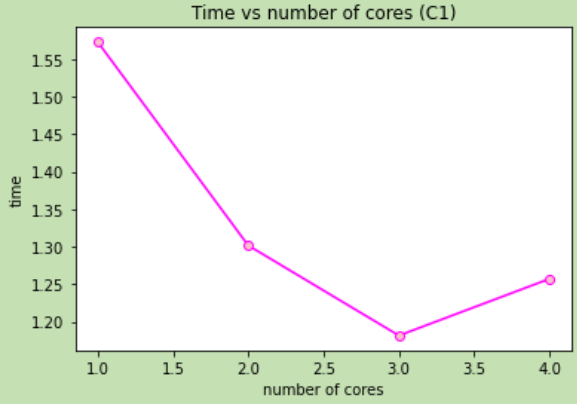

C1: روش Bisecting K-means برای فایل اول با k= 4:

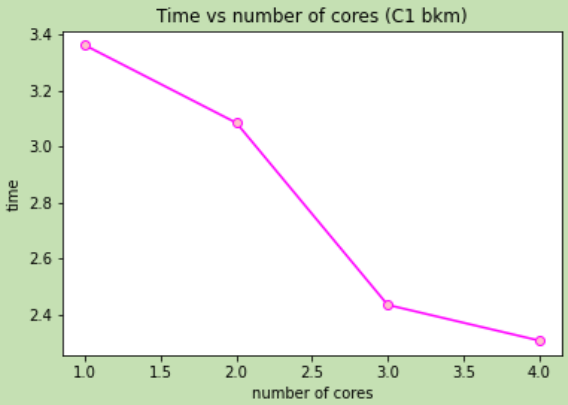

C2: نمودار روش kmeans++ برای فایل دوم با k= 3:

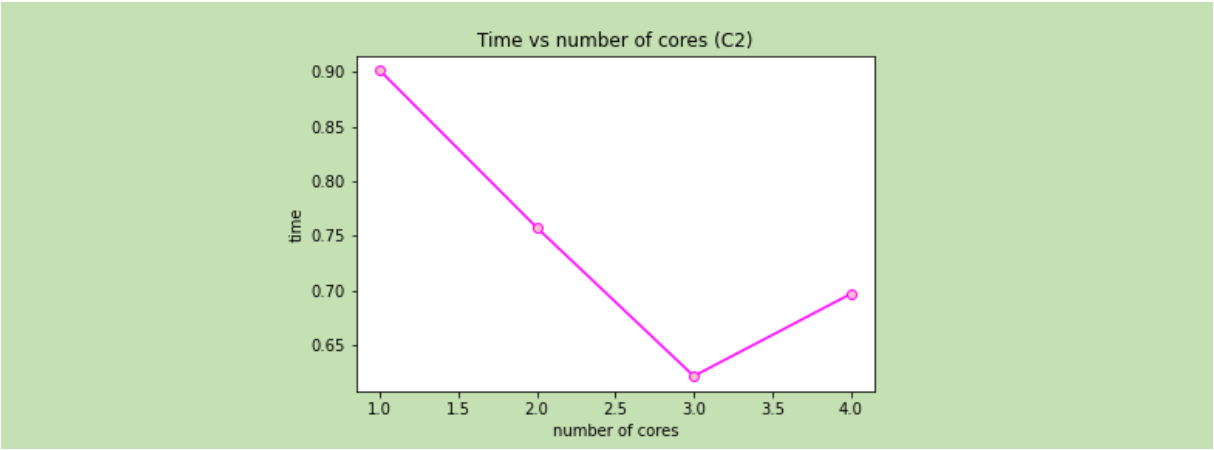

C2: روش Bisecting K-means برای فایل دوم با k= 4:

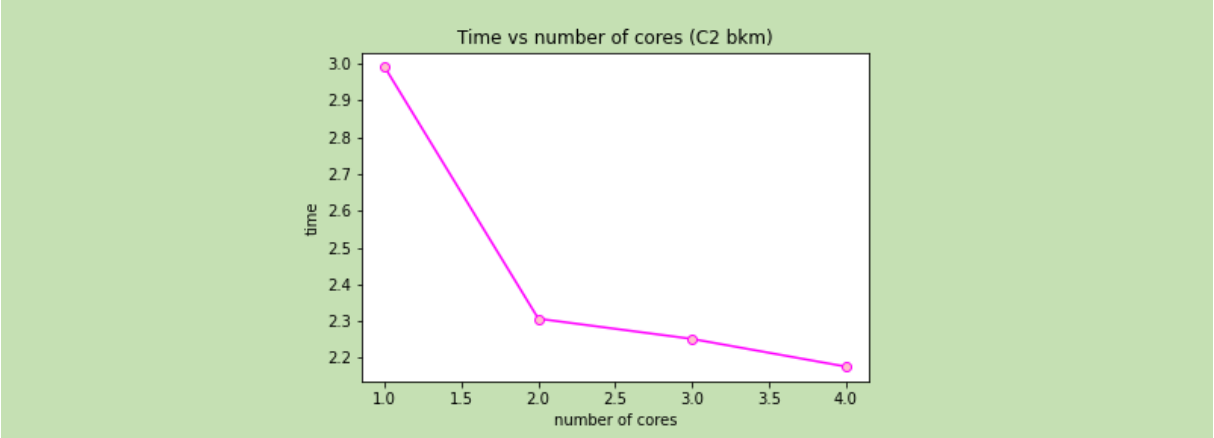

C3: نمودار روش kmeans++ برای فایل سوم با k= 12:

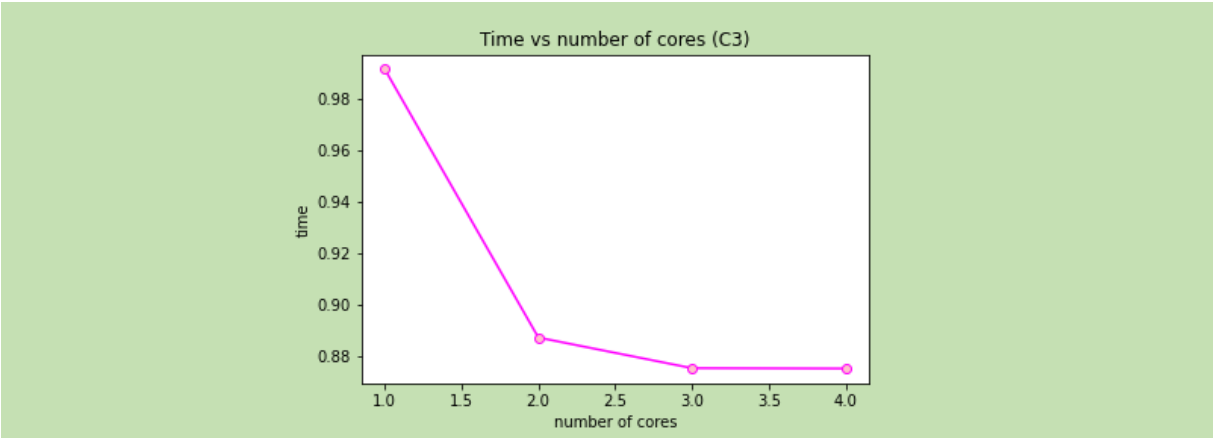

C3: روش Bisecting K-means برای فایل سوم با k= 4:

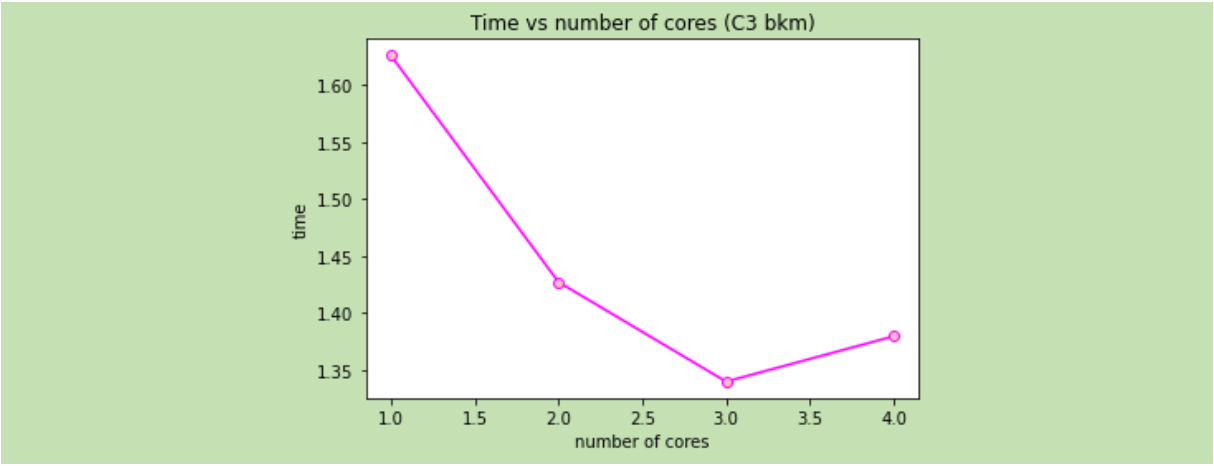

باتوجه به نمودارهای به دست آمده میتوان متوجه شد که هرچه تعداد هسته های پردازشگر را افزایش دهیم سرعت محاسبات بیشتر شده و زمان کاهش می یابد و همچنین با توجه به مقادیر نمودارها به نظر میرسد که روش Bisecting K-means در مجموع زمان بیشتری را برای محاسبات نسبت به kmeans++ میخواهد و درواقع روش کندتری است.